Hibrit Analiz ve Anomali Tespiti ile Sahte İş İlanlarının Belirlenmesi

1. Proje Amacı

Bu projenin temel amacı; sahte iş ilanlarını tespit etmek için metin tabanlı **Doğal Dil İşleme (NLP)** yöntemlerini, **istatistiksel anomali tespiti** teknikleriyle harmanlayan hibrit bir denetim mekanizması geliştirmektir. Mevcut NLP modelinin sunduğu yüksek başarıyı, içerikten bağımsız yapısal aykırılıklarla destekleyerek sistemin genel güvenilirliğini artırmak hedeflenmektedir.

2. Metodoloji ve İş Akışı

A. Metin Tabanlı Sınıflandırma

Projenin ilk ayağında, iş ilanlarının içeriği (başlık, açıklama, gereksinimler) üzerinden bir modelleme yapılmıştır:

- **Ön İşleme:** Metinler temizlenerek gürültüden arındırılmıştır.
- **Vektörleştirme:** TF-IDF yöntemiyle kelimelerin metin içindeki ağırlıkları sayısal vektörlere dönüştürülmüştür.
- **Model:** Logistic Regression (Sınıf ağırlıklı/Balanced) kullanılarak **%95 başarı** seviyesine ulaşılmıştır.

B. İstatistiksel Anomali Tespiti

Sadece metne bakmak yerine, ilanların "normal dışı" davranışlarını yakalamak için aşağıdaki yapısal özellikler analiz edilmektedir:

- **Sıklık Analizi:** Kısa süre içinde aynı lokasyondan veya aynı şirket adı altında çıkan aşırı ilan sayısı.
- **Eksik Veri Profili:** Sahte ilanların genellikle belirli alanları (şirket logosu, web sitesi vb.) boş bırakma eğilimlerinin modeldeki ağırlığı.
- **Dağılım Analizi:** İlan verilerindeki sayısal özelliklerin normal dağılımdan sapma oranları.

C. Datasets (Veri Setleri)

Projenin temelini oluşturan veriler, hem metinsel hem de yapısal analiz için iki ana boyutta incelenmektedir:

- **Primary Source:** Kaggle üzerinden erişilen **"Real / Fake Job Posting Prediction"** veri seti.
- **Data Content:** Yaklaşık 18.000 ilan; şirket bilgileri, iş tanımları, gereksinimler, lokasyon, maaş aralığı ve ilanın gerçeklik durumu ya da label bilgilerini içerir.
- **Data Characteristics:** Veri setindeki sınıflar arası dengesizlik , sahte ilanların azınlıkta olması nedeniyle **Class Weighting** tekniğiyle işlenmektedir.

3. Kullanılan Teknikler ve Algoritmalar

Proje kapsamında sahte ilanları ayıklamak için şu hibrit yaklaşım benimsenmiştir:

- **NLP:** Logistic Regression (Sınıflandırıcı).
- **Anomali Tespiti:** * **Isolation Forest:** Veri kümesindeki uç değerleri (aykırı ilanları) izole eder.
- **Local Outlier Factor (LOF):** İlanların yoğunluk bazlı yerel sapmalarını hesaplar.

4. Hedeflenen Sonuçlar

Proje tamamlandığında elde edilecek sistemin şunları sağlaması beklenmektedir:

1. **Daha Düşük Yanıltıcı Alarm (False Positive):** Sadece şüpheli kelimeler içeren değil, aynı zamanda şüpheli davranışlar sergileyen ilanların önceliklendirilmesi.
2. **Davranışsal Tespit:** Dolandırıcıların metinleri değiştirmesi durumunda bile, ilan verme sıklığı ve lokasyon gibi yapısal anomaliler üzerinden tespitin devam etmesi.

Referanslar ve Kaynaklar

- **Kod Tabanı:** https://github.com/SirSiestaLord/Ingilizce_Sahte_Is_Ilan_Belirleyici
- **Veri Kaynağı:** Real / Fake Job Posting Prediction - Kaggle
- **Yöntem:** NLP & Anomaly Detection Techniques
- Anbarasu, V., Selvakani, S., & Vasumathi, M. K. (2024). Fake Job Prediction Using Machine Learning. ubiquity, 13(1), 12-20.